

Avaliação de Modelos de Visão Computacional para Classificação de Lesões de Pele

Rafaela Miglinski Lucca¹

¹Institute of Mathematics and Computer Sciences (ICMC)
Graduate Program in Computer Science and Computational Mathematics
University of São Paulo (USP), São Carlos, SP, Brazil

rafaelalucca@usp.br

Resumo. A classificação automática de lesões de pele tem sido amplamente explorada por técnicas de aprendizado profundo, impulsionada pela disponibilidade de bases de imagens dermatoscópicas cada vez maiores. Neste trabalho, realizamos um estudo comparativo utilizando o conjunto HAM10000, composto por 10.015 imagens distribuídas em sete categorias de lesões. O objetivo não foi identificar um único modelo vencedor, mas analisar como diferentes arquiteturas se comportam quando submetidas às mesmas condições de treinamento e avaliação.

Foram comparadas duas estratégias distintas: a utilização de características extraídas por um modelo auto-supervisionado congelado (DINOv2) combinadas a um classificador SVM e o ajuste fino de cinco arquiteturas modernas de visão computacional (ConvNeXt V2, EfficientNetV2-S, ConvNeXt, Swin Transformer e MaxViT). Para evitar vazamento de informação entre os conjuntos de dados, a divisão foi realizada de forma agrupada por lesão. Também foram empregadas técnicas para lidar com o desbalanceamento das classes e métricas mais adequadas a esse cenário, como balanced accuracy, macro-F1 e revocação por classe.

Os resultados mostram que os modelos ajustados superaram consistentemente a abordagem baseada em características congeladas, alcançando valores de macro-F1 entre 0,71 e 0,72. Além disso, observou-se que pequenas diferenças na acurácia global podem ocultar comportamentos bastante distintos nas classes minoritárias, especialmente no melanoma. As análises indicam que a escolha da arquitetura deve considerar não apenas o desempenho geral, mas também sua capacidade de identificar corretamente lesões clinicamente relevantes.

1. Introdução

O câncer de pele é uma das neoplasias mais comuns no mundo, e a identificação precoce de lesões malignas está associada a melhores perspectivas de tratamento. Nos últimos anos, o avanço de técnicas de aprendizado profundo tem impulsionado o desenvolvimento de métodos capazes de auxiliar a análise de imagens dermatoscópicas, contribuindo para a classificação automática de diferentes tipos de lesões de pele.

O conjunto HAM10000 [1] tornou-se uma das principais bases utilizadas para avaliação desses métodos. A base reúne 10.015 imagens dermatoscópicas distribuídas em

sete categorias diagnósticas e apresenta desafios importantes, como o forte desbalanceamento entre classes e a semelhança visual existente entre algumas lesões.

Grande parte dos trabalhos relacionados ao HAM10000 tem como objetivo maximizar o desempenho de um modelo específico. Neste projeto, buscou-se uma perspectiva diferente. O foco foi comparar arquiteturas distintas sob as mesmas condições experimentais, analisando como cada abordagem se comporta diante do mesmo conjunto de dados e do mesmo protocolo de treinamento e avaliação.

Foram consideradas duas abordagens. A primeira utiliza o modelo DINOv2 [2] como extrator de características, mantendo seus parâmetros congelados e empregando uma Support Vector Machine (SVM) para realizar a classificação. A segunda consiste no ajuste fino de cinco arquiteturas amplamente utilizadas em visão computacional: ConvNeXt V2 [3], EfficientNetV2 [4], ConvNeXt, Swin Transformer [5] e MaxViT [6].

Como o HAM10000 contém múltiplas imagens associadas à mesma lesão, foi adotada uma estratégia de divisão agrupada por lesão para evitar vazamento de informação entre os conjuntos de treinamento, validação e teste. A avaliação dos modelos foi realizada por meio de métricas adequadas ao cenário desbalanceado da base, incluindo balanced accuracy, macro-F1 e revocação por classe. Também foram conduzidas análises de interpretabilidade utilizando t-distributed Stochastic Neighbor Embedding (t-SNE) e Gradient-weighted Class Activation Mapping (Grad-CAM) [8].

2. Base de Dados

O conjunto HAM10000 [1] é composto por 10.015 imagens dermatoscópicas coloridas distribuídas em sete categorias diagnósticas: nevo melanocítico (nv), melanoma (mel), ceratose benigna (bkl), carcinoma basocelular (bcc), ceratose actínica ou doença de Bowen (akiec), lesão vascular (vasc) e dermatofibroma (df). Além das imagens, a base disponibiliza informações complementares, como idade, sexo, localização anatômica da lesão e método de confirmação diagnóstica.

A análise exploratória revelou dois aspectos importantes da base. O primeiro é a distribuição desigual entre as classes. A categoria nv representa aproximadamente dois terços de todas as amostras, enquanto classes como df e vasc possuem poucas observações. Essa diferença tende a favorecer métricas globais de desempenho e dificulta a avaliação das classes menos frequentes.

O segundo aspecto está relacionado à presença de múltiplas imagens associadas à mesma lesão, identificadas pelo atributo `lesion_id`. Como uma mesma lesão pode aparecer em diferentes imagens, uma divisão realizada apenas por imagem permitiria que exemplos da mesma lesão fossem incluídos simultaneamente nos conjuntos de treinamento e teste. Esse cenário produz estimativas excessivamente otimistas de desempenho e não reflete adequadamente a capacidade de generalização dos modelos.

A Figura 1 apresenta a distribuição das classes e exemplos de imagens pertencentes a cada categoria diagnóstica.




Figura 1. À esquerda, distribuição das classes presentes no conjunto HAM10000. À direita, exemplos de imagens dermatoscópicas das sete categorias diagnósticas.

3. Metodologia

3.1. Formulação do problema

O problema foi tratado como uma tarefa de classificação multiclasse supervisionada. A entrada do modelo consiste em uma imagem dermatoscópica, enquanto a saída corresponde a uma das sete categorias diagnósticas presentes no conjunto HAM10000. Todas as imagens foram redimensionadas para 224×224 pixels e normalizadas utilizando as estatísticas do ImageNet, seguindo o procedimento adotado pelos modelos pré-treinados empregados neste trabalho.

3.2. Divisão dos dados e tratamento do desbalanceamento

O conjunto HAM10000 possui múltiplas imagens associadas à mesma lesão, identificadas pelo atributo `lesion_id`. Para evitar que imagens da mesma lesão fossem distribuídas entre treinamento e teste, foi utilizada uma estratégia de validação cruzada estratificada e agrupada por lesão, garantindo a preservação da distribuição das classes e impedindo que uma mesma lesão estivesse presente em mais de um conjunto de dados.

O desbalanceamento entre as classes foi tratado de duas formas. Na primeira, foram utilizados pesos de classe calculados a partir da raiz da frequência inversa de cada categoria e incorporados à função de perda. Na segunda, foi empregada a técnica MixUp [7] em conjunto com uma estratégia de amostragem balanceada, aumentando a probabilidade de seleção de exemplos pertencentes às classes menos frequentes durante o treinamento.

Também foram aplicadas transformações de aumento de dados para ampliar a variabilidade das imagens observadas pelos modelos. Entre elas estão recortes aleatórios, espelhamentos horizontal e vertical e transformações aleatórias de intensidade e geometria. Além disso, utilizou-se label smoothing com fator igual a 0,05, reduzindo a confiança excessiva das previsões durante o treinamento.

3.3. Modelos comparados

Foram avaliadas duas abordagens para a classificação das lesões de pele.

A primeira utiliza o DINOv2 [2], um modelo baseado na arquitetura Vision Transformer (ViT), como extrator de características. Nesse cenário, os parâmetros do modelo permanecem congelados e cada imagem é representada por um vetor de características com 768 dimensões. Após uma etapa de padronização, esses vetores são utilizados para treinar uma Support Vector Machine (SVM) com núcleo radial (RBF). Os hiperparâmetros do classificador foram selecionados com base no desempenho obtido no conjunto de validação, utilizando a métrica macro-F1.

A segunda abordagem consiste no ajuste fino de cinco arquiteturas pré-treinadas: ConvNeXt V2 [3], EfficientNetV2-S [4], ConvNeXt, Swin Transformer [5] e MaxViT [6]. O treinamento foi realizado em duas etapas. Inicialmente, apenas a camada de classificação foi atualizada, permitindo sua adaptação ao novo problema. Em seguida, todos os parâmetros da rede foram liberados para ajuste.

A otimização foi realizada com o algoritmo AdamW. A taxa de aprendizado foi reduzida gradualmente ao longo do treinamento por meio de um agendamento baseado em cosseno, e o processo foi interrompido quando não foram observadas melhorias no conjunto de validação durante um número pré-definido de épocas. Na etapa de teste, cada imagem foi avaliada em diferentes versões transformadas e as previsões resultantes foram combinadas para produzir a classificação final.

3.4. Métricas

Devido ao desbalanceamento presente no conjunto HAM10000, a acurácia foi utilizada apenas como uma métrica complementar. Como a classe nv representa aproximadamente 66,95% das amostras da base, um modelo pode apresentar elevada acurácia mesmo obtendo baixo desempenho nas classes menos frequentes. Por esse motivo, a avaliação foi baseada principalmente em balanced accuracy, macro-F1 e revocação por classe. Também foi analisada a revocação da classe melanoma, uma vez que a não identificação desse tipo de lesão representa o erro de maior impacto clínico.

4. Experimentos e Resultados

Os experimentos foram realizados no Google Colab utilizando uma GPU NVIDIA T4. A Tabela 1 apresenta os resultados obtidos no conjunto de teste, composto por 2.014 imagens.

Tabela 1. Desempenho dos modelos no conjunto de teste.

Modelo	Acc.	Bal. Acc.	Macro-F1	Rec. Mel.
EfficientNetV2-S	0,822	0,738	0,720	0,644
Swin Transformer	0,835	0,713	0,716	0,734
ConvNeXt V2	0,811	0,722	0,713	0,748
ConvNeXt	0,825	0,712	0,710	0,680
MaxViT	0,785	0,658	0,628	0,495
DINOv2 + SVM	0,805	0,583	0,601	0,536

Os resultados mostram que os modelos submetidos ao ajuste fino apresentaram desempenho superior à abordagem baseada em características extraídas pelo DINOv2 e

classificadas por uma Support Vector Machine. As quatro arquiteturas com melhor desempenho obtiveram valores de macro-F1 muito próximos, variando entre 0,710 e 0,720. Isso sugere que, sob o protocolo experimental adotado, não existe um único modelo claramente superior aos demais.

Quando a análise é direcionada para a classe melanoma, algumas diferenças tornam-se mais evidentes. O ConvNeXt V2 apresentou a maior revocação, seguido pelo Swin Transformer. Como o melanoma é a classe de maior interesse clínico, esses resultados indicam que pequenas diferenças na acurácia global podem esconder comportamentos bastante distintos na identificação das lesões mais críticas.

Também foi avaliado o impacto da estratégia de balanceamento baseada em MixUp. Para isso, o EfficientNetV2-S foi treinado em duas configurações: uma utilizando pesos de classe na função de perda e outra utilizando MixUp. Os resultados são apresentados na Tabela 2.

Tabela 2. Comparação entre pesos de classe e MixUp utilizando o EfficientNetV2-S.

Estratégia	Acc.	Bal. Acc.	Macro-F1	Rec. Mel.
Pesos de classe	0,841	0,688	0,685	0,559
MixUp	0,822	0,738	0,720	0,644

Observa-se que o uso de MixUp reduziu a acurácia global, mas resultou em ganhos nas demais métricas avaliadas. O aumento da balanced accuracy, da macro-F1 e da revocação do melanoma indica que essa estratégia favoreceu um comportamento mais equilibrado entre as diferentes classes da base.

Além da análise quantitativa, foram realizadas visualizações para auxiliar a interpretação dos resultados. A Figura 2 apresenta a projeção t-distributed Stochastic Neighbor Embedding (t-SNE) das características extraídas pelo DINOv2 e a matriz de confusão obtida pelo ConvNeXt V2. Observa-se uma sobreposição considerável entre as classes melanoma e nevo melanocítico, o que ajuda a explicar parte dos erros observados pelos modelos durante a classificação.




Figura 2. À esquerda, projeção t-SNE das características extraídas pelo DINOv2. À direita, matriz de confusão do ConvNeXt V2 no conjunto de teste.

A Figura 3 apresenta exemplos de classificações incorretas do ConvNeXt V2. Os erros mais frequentes ocorrem entre melanoma e nevo melanocítico: há nevos previstos como melanoma (falsos alarmes, toleráveis em um cenário de triagem) e, em sentido oposto e clinicamente mais grave, melanomas previstos como nevos. Observam-se ainda confusões entre ceratose benigna (bkl) e carcinoma basocelular (bcc), lesões de aparência dermatoscópica semelhante.




Figura 3. Exemplos de classificações incorretas do ConvNeXt V2, com o rótulo real e o predito. Predominam confusões entre melanoma e nevo melanocítico.

5. Discussão

Os resultados mostram que EfficientNetV2-S, Swin Transformer, ConvNeXt V2 e ConvNeXt apresentaram desempenhos muito próximos, sem que uma arquitetura se destacasse

claramente nas métricas globais. Quando a análise é direcionada ao melanoma, o ConvNeXt V2 e o Swin Transformer obtiveram os melhores resultados de revocação, métrica particularmente relevante para aplicações de triagem.

A comparação entre o DINOv2 combinado com uma Support Vector Machine e os modelos submetidos ao ajuste fino favoreceu consistentemente a segunda abordagem. Em todas as métricas avaliadas, os modelos ajustados apresentaram desempenho superior, indicando que a adaptação dos parâmetros ao problema específico trouxe benefícios para a classificação das lesões.

O uso de MixUp melhorou a balanced accuracy, a macro-F1 e a revocação do melanoma, embora tenha reduzido a acurácia global. Esse resultado sugere um tratamento mais equilibrado das classes da base, especialmente das categorias menos representadas.

Entre as limitações do estudo, destaca-se o pequeno número de amostras da classe dermatofibroma (df) no conjunto de teste, o que aumenta a variabilidade das métricas dessa categoria. Além disso, as visualizações obtidas por meio do Grad-CAM indicam que parte das decisões dos modelos pode ser influenciada por artefatos presentes nas imagens, aspecto que merece investigação adicional.

6. Conclusão

Este trabalho apresentou uma comparação entre diferentes abordagens para a classificação de lesões de pele utilizando o conjunto HAM10000. Os resultados mostraram que os modelos submetidos ao ajuste fino obtiveram desempenho superior à estratégia baseada em características extraídas pelo DINOv2 e classificadas por uma Support Vector Machine. Entre os modelos avaliados, EfficientNetV2-S, Swin Transformer, ConvNeXt V2 e ConvNeXt apresentaram resultados muito próximos, indicando que arquiteturas distintas podem alcançar níveis semelhantes de desempenho quando treinadas sob as mesmas condições.

A análise também mostrou que a escolha da métrica influencia diretamente a interpretação dos resultados. Embora alguns modelos tenham apresentado maior acurácia, diferenças mais relevantes foram observadas na balanced accuracy, na macro-F1 e na revocação do melanoma, métricas mais adequadas ao cenário desbalanceado do HAM10000.

Como trabalhos futuros, podem ser exploradas estratégias de validação cruzada agrupada para reduzir a dependência de uma única divisão dos dados, além da investigação de funções de perda mais adequadas para classes minoritárias, como a focal loss. Também podem ser avaliadas combinações dos modelos com melhor desempenho e técnicas voltadas à redução da influência de artefatos presentes nas imagens dermatoscópicas.

Referências

- [1] Tschandl, P., Rosendahl, C. and Kittler, H. (2018). The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions. *Scientific Data*, 5, 180161.
- [2] Oquab, M. et al. (2023). DINOv2: Learning Robust Visual Features without Supervision. *arXiv:2304.07193*.

- [3] Woo, S. et al. (2023). ConvNeXt V2: Co-designing and Scaling ConvNets with Masked Autoencoders. In *CVPR*.
- [4] Tan, M. and Le, Q. (2021). EfficientNetV2: Smaller Models and Faster Training. In *ICML*.
- [5] Liu, Z. et al. (2021). Swin Transformer: Hierarchical Vision Transformer using Shifted Windows. In *ICCV*.
- [6] Tu, Z. et al. (2022). MaxViT: Multi-Axis Vision Transformer. In *ECCV*.
- [7] Zhang, H. et al. (2018). mixup: Beyond Empirical Risk Minimization. In *ICLR*.
- [8] Selvaraju, R. R. et al. (2017). Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization. In *ICCV*.
- [9] Wightman, R. (2019). PyTorch Image Models (timm). <https://github.com/huggingface/pytorch-image-models>.